

Desafio Técnico - Ciência de Dados

Gato Mestre | Previsão de Pontuação de Atletas

Contexto

O Gato Mestre (GM) é o produto de dados e estatísticas esportivas do Grupo Globo, responsável por alimentar o Cartola FC e o ecossistema ge.

A cada rodada do Campeonato Brasileiro, antes do fechamento do mercado, milhões de participantes escalam um time de atletas dentro de um orçamento limitado em cartoletas. As informações hoje disponíveis para apoiar essa decisão são majoritariamente descritivas: média de pontuação, preço e histórico recente do atleta.

O time de produto avalia lançar uma previsão de pontuação por atleta, exibida no aplicativo e no site do Cartola durante a montagem do time. Seria uma das informações mais visíveis do produto, consultada por milhões de usuários a cada rodada - e, por isso, a decisão de lançá-la depende de evidência de que a previsão é confiável o suficiente para orientar a escalação.

Objetivo

Construir uma solução de modelagem que estime a pontuação de cada atleta na próxima rodada, e demonstrar se ela sustenta esse uso.

A escolha da abordagem, das técnicas e das variáveis é sua, e faz parte do que será avaliado.

Foco técnico

Avaliaremos os métodos de limpeza, pré-processamento e engenharia de variáveis (feature engineering), a estratégia de validação adotada e a justificativa técnica do modelo escolhido.

A organização e a legibilidade do código também entram na avaliação: um modelo em produção é mantido por outras pessoas do time, não apenas por quem o construiu.

Contexto da posição

A vaga atua na interseção entre ciência de dados e engenharia: além da modelagem, envolve a estruturação de pipelines de dados, a disponibilização de modelos em produção e o acompanhamento contínuo de suas métricas.

Como o desafio é executado fora do nosso ambiente, considerações de arquitetura, provisionamento e operação podem ser demonstradas por meio de código, estrutura e documentação - não é necessário que estejam efetivamente implantadas.

Material recebido

Arquivo	Conteúdo
Desafio Tecnico - Ciencia de Dados.pdf	Este documento
Dicionario de Dados.pdf	Descrição dos campos da base
API de Dados Esportivos.pdf	Documentação da API de apoio
base_case_gm.csv	Histórico de desempenho e mercado dos atletas, por rodada

api_apoio/servidor.py	Serviço da API
api_apoio/api_dataset.json	Dado interno do serviço acima - não é fonte do desafio

A base concentra o histórico de desempenho e mercado dos atletas. A API complementa esse histórico com o contexto das partidas - confrontos, mando de campo, escalações e cadastro de atletas.

api_apoio/api_dataset.json existe porque o serviço precisa carregar os dados de algum lugar - não é um atalho. O contexto de partidas deve ser obtido pelos endpoints documentados em API de Dados Esportivos.pdf, não por leitura direta do arquivo.

Para subir a API:

```
python api_apoio/servidor.py
```

Depende apenas da biblioteca padrão do Python 3.10 ou superior. O serviço ocupa o terminal enquanto estiver no ar e exibe o token de acesso ao iniciar. Consulte o documento da API para os endpoints, a autenticação e o comportamento de erro.

A avaliação da consistência dos dados recebidos e a definição de como as duas fontes se combinam fazem parte do desafio.

Ambiente

Você tem liberdade para escolher bibliotecas e ferramentas. O único requisito rígido é que a sua solução seja reproduzível: precisamos conseguir executá-la a partir das suas instruções.

Questões para Resposta

Após o desenvolvimento, envie os resultados obtidos e responda às questões a seguir:

1. Que inconsistências você encontrou na base? Para cada uma, qual foi o tratamento adotado e por quê?
2. Como você dividiu os dados entre treino e validação? Justifique tecnicamente o critério escolhido.
3. Quais colunas da base você utilizou como variáveis do modelo, e quais deixou de fora? Explique os dois lados da decisão.
4. Que métricas você usou para avaliar o modelo, e por quê? O resultado obtido justifica colocar a solução em uso?

Respostas objetivas são suficientes. O que interessa é o critério por trás de cada decisão, não a extensão do texto. Os demais aspectos da solução serão conversados na apresentação.

Entregáveis

1. Notebook da modelagem, com instruções de execução, contemplando:

- o tratamento aplicado aos dados e as decisões tomadas
- a análise exploratória
- a construção das variáveis utilizadas
- o ajuste e a avaliação do modelo
- as respostas às questões acima, junto da análise que as sustenta

Esperamos acompanhar o raciocínio do início ao fim: o que foi encontrado, o que foi decidido e por quê.

2. previsoes.json - o resultado gerado, no contrato descrito abaixo.

3. Código do serviço que expõe esse resultado. Pode estar no próprio notebook ou em arquivo separado, com instruções de execução.

No produto, a previsão é consumida pelo aplicativo e pelo site - não por quem a produziu.

4. Material da apresentação, contemplando a análise, os resultados obtidos e as recomendações decorrentes.

Contrato da previsão

Cada previsão reproduz o formato usado hoje em produção - uma entrada por atleta e rodada:

```
{
  "atleta_id": 10023,
  "ano": 2025,
  "rodada_id": 30,
  "clube_id": 107,
  "posicao_id": 4,
  "pontos_predito": 6.04,
  "data_predicao": "2025-10-15T14:32:00Z"
}
```

O arquivo previsoes.json reúne todas elas sob a chave previsoes:

```
{
  "previsoes": [
    {"atleta_id": 10023, "ano": 2025, "rodada_id": 30, "...": "..."},
    {"atleta_id": 10024, "ano": 2025, "rodada_id": 31, "...": "..."}
  ]
}
```

Como ano e rodada_id estão em cada previsão, o arquivo comporta quantas rodadas você quiser - não é preciso um arquivo por rodada.

O serviço expõe esse mesmo conteúdo. O formato da previsão acima é o que precisa ser respeitado; o desenho da interface é seu - quais rotas, se aceita filtros por rodada ou atleta, como responde quando não há previsão.

Campos adicionais são bem-vindos, desde que os acima estejam presentes. A tecnologia do serviço é sua escolha.

Quais rodadas entregar: todas as que o seu recorte de avaliação cobrir - o período que você separou para testar o modelo. Não é preciso prever a temporada inteira; o que interessa é que as previsões entregues sejam as que você não usou para treinar.

Prazo e apresentação

Estimamos um tempo de dedicação de 5 a 7 dias. Pedimos que o material seja enviado com pelo menos 1 dia de antecedência da data da apresentação.

Envie tudo em um arquivo compactado ou pelo link de um repositório - o que for mais conveniente. Precisamos conseguir executar o que você entregou a partir das suas instruções.

Ao final, realizaremos uma reunião de 60 minutos para a apresentação dos resultados e das propostas de melhoria.

A apresentação é dirigida ao nosso time técnico de dados. Não é preciso traduzir para um público leigo - você pode entrar nos detalhes de método, decisões e trade-offs diretamente. Ainda assim, a clareza da comunicação é avaliada: uma análise boa mal explicada também é entrega incompleta.

Critérios de avaliação

Avaliamos cinco eixos: tratamento dos dados, rigor da validação, modelagem, engenharia e comunicação.

A consistência do método e a clareza da justificativa técnica são mais relevantes que a complexidade do modelo escolhido.

Dúvidas

Em caso de dúvida sobre o enunciado ou sobre os dados, entre em contato. Caso identifique uma ambiguidade e opte por seguir com uma interpretação própria, registre a suposição adotada na sua entrega.

Boa sorte.